

MATRIZ DE COSTOS

MATRIZ DE COSTOS - ANÁLISIS DE MODELOS IA

Sistema de Soporte Técnico Automatizado

RESUMEN EJECUTIVO

Concepto	Costo Mensual	Anual	Notas
----- ----- ----- -----			
Cohere API (Command R)	USD \$50-100	USD \$600-1.200	RAG, ~500-1000 tickets/mes
N8N Cloud (Pro tier)	USD \$50-100	USD \$600-1.200	Orquestación, webhooks, historiales
Notion (Team, 5 usuarios)	USD \$120	USD \$1.440	Bases de datos, KB, dashboard
Gmail	Gratuito	—	Mediante Google Workspace (costo corporativo)
Google Sheets	Gratuito	—	Captura inicial de tickets
Mano de obra (HITL)	8-10 hrs/mes	~USD \$400 (@ \$50/hr)	Validación manual + mantenimiento KB
TOTAL ESTIMADO	**USD \$620-370**	**USD \$4.440-6.240**	Incluye HITL

1. DESGLOSE POR INTEGRACION

1.1 COHERE API (Command R-08-2024)

Precios Base (Cohere Pricing)
- **Token de entrada:** \$0.0005 por 1K tokens
- **Token de salida:** \$0.0015 por 1K tokens
Cálculo de Tokens por Ticket
Input Prompt:
- Contexto del ticket: ~150 tokens
- KB (8 artículos × 200 tokens): ~1.600 tokens
- Instrucciones de sistema: ~800 tokens
- **Total input:** ~2.550 tokens por ticket
Output Respuesta:
- Respuesta sugerida + metadata: ~400 tokens
Tokens totales por ticket: 2.550 + 400 = **2.950 tokens**
Coste por Ticket
...
Input: 2.550 tokens ÷ 1.000 × \$0.0005 = \$0.00128
Output: 400 tokens ÷ 1.000 × \$0.0015 = \$0.0006
Total: \$0.00188 por ticket
...
Proyección Mensual (Escenarios)
Tickets/mes Coste Cohere Con retries (×1.2) Observaciones
----- ----- ----- -----
100 \$0.19 \$0.23 Departamento pequeño
500 \$0.94 \$1.13 Empresa mediana (actual)
1000 \$1.88 \$2.26 Escalado, multi-sede
2000 \$3.76 \$4.51 Máximo recomendado
Costo anual (500 tickets/mes): USD \$11.36

1.2 N8N CLOUD (Plan Pro)

Tiers Disponibles

Plan	Precio	Ejecuciones/mes	API Calls	Historial	Uso Recomendado
Free	\$0	10.000	Limitado	3 días	Pruebas
Pro	\$50	200.000	20.000	90 días	**← Actual**
Business	\$150	500.000	50.000	6 meses	Empresas grandes
Enterprise	Custom	Ilimitado	Ilimitado	Ilimitado	Crítico

Cálculo de Ejecuciones Reales

****Flujo principal (1 trigger + 11 nodos):****

- Google Sheets Trigger: 1 ejecución/minuto = 1.440 ejecuciones/día
- Pero: Solo se ejecuta si hay cambio nuevo → ~50 tickets/día = ~50 executions/día

****Flujo secundario (Notion Trigger + 3 nodos):****

- Se dispara cuando humano aprueba (1-2 veces por ticket)
- ~50 tickets × 1-2 aprobaciones = ~50-100 ejecuciones/día

****Total estimado:****

- 50 tickets/día × 30 días = 1.500 tickets/mes
- Primary flow: 1.500 × 11 nodos = 16.500 ejecuciones
- Secondary flow: 1.500 × 3 nodos = 4.500 ejecuciones
- ****Total: 21.000 ejecuciones/mes → DENTRO DEL PLAN PRO (200.000)****

****Costo N8N:**** USD \$50/mes (plan actual es suficiente)

1.3 NOTION (Plan Team)

Precios de Notion

Plan	Precio/usuario	Usuarios	Bases	Características
Free	\$0	5	Ilimitadas	Básico
Plus	\$100/mes	Ilimitados	Ilimitadas	Avanzado
Business	\$200/mes	Ilimitados	Ilimitadas	Integración API
Enterprise	Custom	Custom	Custom	Custom SLA

****Plan actual recomendado:**** Business (\$200/mes)

- Razón: Necesita Notion API para leer/escribir en base de datos
- Plus (\$100/mes) podría funcionar si se usa solo como lectura

****Usuarios (estimado):****

- Admin de tickets: 1
- Revisores (HITL): 2-3
- Soporte nivel 2: 2
- Observadores: 1
- ****Total: ~6 usuarios****

****Costo Notion:**** USD \$200/mes (Business plan)

1.4 GOOGLE WORKSPACE

Componentes

- Google Sheets: Incluido en Workspace
- Gmail (soporte@empresa): ~\$15-20/usuario/mes

****Para este proyecto:****

- Sheets + Gmail (1 cuenta soporte): USD \$15-20/mes (asumido dentro de IT corporativo)

1.5 GMAIL (HITL + NOTIFICACIONES)

Tipo de Email	Volumen	Costo
---------------	---------	-------

Notificación a revisor	1 por ticket	Gratuito (Workspace)
------------------------	--------------	----------------------

| Respuesta a usuario | 1 por ticket aprobado | Gratuito (Workspace) |
| Escalamiento/Errores | 1 cada 100 tickets | Gratuito (Workspace) |
Costo Gmail: INCLUIDO EN WORKSPACE

2. ANÁLISIS POR TIPO DE TAREA

2.1 Clasificación de Tickets (Agente IA)

Modelo: Cohere Command R (temperatura = 0)

Ventaja: Determinista, RAG native, bajo costo

Costo: \$0.00188/ticket

Alternativas evaluadas:

| Modelo | Precio | Pros | Contras | Recomendación |

|-----|-----|-----|-----|-----|

| Cohere Command R | \$0.0005 in / \$0.0015 out | RAG native, bajo costo | Menos popular | ✓

ACTUAL |

| Claude 3.5 Sonnet | \$0.003 in / \$0.015 out | Muy capaz, mejor RAG | 8x más caro | Alternativa premium |

| GPT-4o-mini | \$0.00015 in / \$0.0006 out | Más barato | Menos RAG | Alternativa económica |

| Llama-3 (self-hosted) | \$50 setup + \$5/mes | Sin API fees | Requiere infraestructura | No viable |

Análisis costo/beneficio:

- **GPT-4o-mini:** 4x más barato (\$0.00047/ticket), pero menos precisión en RAG

- Ahorraría USD \$6-7/mes, pero riesgo de respuestas pobres

- **Recomendación:** Para volúmenes >2000/mes o presupuesto ajustado

- **Claude 3.5 Sonnet:** 8x más caro, pero mejor comprensión

- Costaría ~USD \$15/mes para 500 tickets

- **Recomendación:** Para tickets complejos/CISO o si presupuesto lo permite

DECISIÓN ACTUAL: Cohere Command R es óptimo (relación costo-calidad)

2.2 Human-in-the-Loop (HITL)

Costo: Tiempo manual ~8-10 hrs/mes @ \$50/hr = USD \$400-500/mes

Desglose:

- Revisión y aprobación: 5 min × 500 tickets = 2.500 min = 41 hrs/mes

- Con N8N notification: 30 seg × 500 = 250 min = 4 hrs/mes (optimizado)

- Mantenimiento KB: 3 hrs/mes (actualizar artículos)

- Debugging/Escalamiento: 2-3 hrs/mes

Total: 9-10 hrs/mes

Optimización posible:

- Autoaprobar tickets con confidence score >95%

- Ahorro: 30% de revisiones = 1.2-1.5 hrs/mes = USD \$60-75/mes

- Riesgo: Aumentar tasa de falsos positivos

3. PROYECCIONES Y ESCENARIOS

3.1 Escenario A: Pequeño (100 tickets/mes)

| Componente | Mensual | Anual |

|-----|-----|-----|

| Cohere API | \$0.19 | \$2.28 |

| N8N Cloud | \$50 | \$600 |

| Notion Business | \$200 | \$2.400 |

| HITL (4 hrs) | \$200 | \$2.400 |

| **TOTAL** | **\$450** | **\$5.400** |

| **Costo por ticket** | **\$4.50** | — |

3.2 Escenario B: Mediano (500 tickets/mes) ← ACTUAL

3.3 Escenario C: Grande (2000 tickets/mes)

— — —

4. OPORTUNIDADES DE AHORRO

4.1 Bajo impacto, alto ROI

Oportunidad	Impacto	Effort	Ahorro anual	Recomendación
Cambiar a GPT-4o-mini	-15% precisión	■ Bajo	USD \$120	Evaluar
Autoaprobar >95% confidence	+30% eficiencia HITL	■ Medio	USD \$1.200-1.500	Sí
Batch API de Cohere	-20% tokens	■ Medio	USD \$50-100	Para >1000/mes
Cache KB en N8N	-10% API calls	■ Medio	USD \$50-100	Después de 3 meses

4.2 Optimización del Prompt

****Actual:**** 800 tokens de instrucciones (muy detallado)

****Optimizado:**** 400 tokens (instructions+examples más compactas)

****Impacto:**** -15% en tokens de entrada = USD \$30-50/mes (500 tickets)

****Esfuerzo:**** 1 hora (refinar prompt, test)

— — —

5. PRESUPUESTO RECOMENDADO

Propuesta 1: Producción actual (500 tickets/mes)

'''

N8N Pro: USD \$50/mes

Notion Business: USD \$200/mes

Cohere API: USD \$1/mes (estimado)

HITL + Manten: USD \$450/mes

[REDACTED]

TOTAL MENSUAL: USD \$701/mes

TOTAL ANUAL: USD \$8.411

— — —

...

■■■■■■■■■■

...

...

...

...

****Fecha de análisis:** Septiembre 2026**

****Versión:** 1.0**

****Responsable:** Vicky Caparroz**

ANEXO: Precios Base (Septiembre 2026)

Cohere

- Command R: \$0.0005 in / \$0.0015 out per 1K tokens
- Batch API: 20% descuento
- Free tier: 100.000 tokens/mes

N8N

- Pro: \$50/mes (200K executions)
- Business: \$150/mes (500K executions)
- Free: 10K executions/mes

Notion

- Plus: \$100/usuario/mes
- Business: \$200/usuario/mes
- Free: 5 usuarios, bases ilimitadas

AWS (si usaras Lambda + RDS)

- Lambda: \$0.0000166667 por GB-segundo
- RDS: \$20-50/mes mínimo
- ****Total:**** USD \$50-100/mes (alternativa mais cara)